

Laporan Praktikum Kontrol Cerdas

Nama : Muhammad Faizal Fachri
NIM : 224308092
Kelas : TKA 7D
Akun Github (Tautan) : github.com/muhammadfaizalfachri

1. Judul Laporan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan kali ini, sebagai berikut:

1. Mahasiswa mampu memahami konsep dasar *Deep Reinforcement Learning* (DRL) dalam sistem kendali
2. Mahasiswa mampu mengimplementasikan agen DRL menggunakan algoritma Deep Q-Network (DQN).
3. Mahasiswa mampu Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan DRL.
4. Mahasiswa mampu Melatih dan menguji agen DRL untuk mengontrol lingkungan secara kompleks.

3. Landasan Teori

Deep Reinforcement Learning (DRL) merupakan penggabungan antara *Reinforcement Learning* (RL) dan *Deep Learning* (DL) yang bertujuan untuk menciptakan sistem pembelajaran otomatis yang mampu mengambil keputusan secara optimal dalam lingkungan yang kompleks. RL sendiri merupakan metode pembelajaran berbasis trial-and-error, di mana agen belajar dari interaksi dengan lingkungan untuk memaksimalkan total reward yang diterima. Namun, pada RL tradisional, fungsi nilai (*value function*) atau fungsi kebijakan (*policy function*) sering kali direpresentasikan menggunakan tabel yang sederhana (misalnya tabel Q pada Q-Learning). Pendekatan ini menjadi tidak efisien ketika ruang keadaan (*state space*) atau ruang aksi (*action space*) sangat besar dan kontinu (Mnih et al., 2015).

OpenAI Gym adalah toolkit sumber terbuka berbasis Python yang dirancang untuk mengembangkan dan membandingkan algoritma reinforcement learning dengan menyediakan antarmuka standar untuk berkomunikasi antara algoritma pembelajaran dan lingkungan, serta seperangkat lingkungan standar yang sesuai dengan antarmuka tersebut (Brockman et al., 2016).

Deep Q-Network (DQN) adalah salah satu algoritma *Reinforcement Learning* berbasis Q-learning yang menggunakan jaringan saraf dalam (deep neural network) untuk memprediksi nilai Q (Q-value) dari setiap aksi yang mungkin diambil oleh agen dalam suatu keadaan tertentu (Mnih et al., 2015).

4. Diskusi

Dikusi:

1. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

Kelebihan:

Salah satu keunggulan utama dari Deep Q-Network (DQN) adalah kemampuannya dalam menangani sistem dengan ruang keadaan (*state space*) yang sangat besar dan kompleks. Berbeda dengan Q-Learning klasik yang menyimpan nilai Q dalam bentuk tabel, DQN menggunakan jaringan saraf tiruan untuk memperkirakan nilai Q dari setiap pasangan keadaan dan aksi. Hal ini memungkinkan DQN diterapkan pada masalah nyata seperti pengendalian robot, permainan video, maupun sistem dinamis yang memiliki banyak variabel. Selain itu, DQN mampu melakukan generalisasi; artinya, ketika dihadapkan pada keadaan yang belum pernah dilihat sebelumnya, model tetap bisa memberikan keputusan yang cukup rasional berdasarkan pola yang telah dipelajari.

Kekurangan:

DQN memiliki beberapa keterbatasan yang perlu diperhatikan. Dari sisi komputasi, DQN jauh lebih berat dibandingkan Q-Learning klasik karena melibatkan pelatihan jaringan saraf yang membutuhkan sumber daya besar seperti GPU dan waktu pelatihan

yang lama. Selain itu, DQN tidak selalu stabil; jika parameter pelatihannya seperti learning rate atau ukuran replay buffer tidak diatur dengan tepat, model bisa gagal konvergen atau bahkan menghasilkan keputusan yang tidak konsisten.

2. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?

Untuk mengadaptasi DQN pada sistem dinamis seperti drone atau robot industri, langkah pertama adalah merancang representasi keadaan (*state*) dan aksi (*action*) yang sesuai dengan karakteristik sistem. Data dari sensor seperti IMU, kamera, atau encoder digunakan untuk membentuk *state*, sedangkan aksi dapat berupa perintah gerak atau perubahan kecepatan motor. Karena sistem dinamis biasanya memiliki ruang aksi yang kontinu, aksi perlu didiskretkan agar dapat diproses oleh DQN, atau digunakan pendekatan tambahan seperti *residual reinforcement learning* yang menggabungkan DQN dengan pengendali klasik seperti PID. Proses pelatihan sebaiknya dilakukan terlebih dahulu di simulator untuk menghindari risiko pada perangkat nyata, dengan teknik seperti *domain randomization* agar hasil pelatihan lebih tahan terhadap perubahan kondisi di dunia nyata. Selama pelatihan, DQN dapat memanfaatkan *experience replay* dan *target network* untuk menjaga stabilitas pembelajaran. Setelah model mencapai performa yang baik di simulasi, kebijakan kontrol dapat diuji secara bertahap di sistem fisik dengan menerapkan batas keamanan agar drone atau robot tetap beroperasi secara aman dan stabil.

5. Assignment

Pada percobaan minggu kelima, eksperimen difokuskan pada implementasi algoritma Deep Q-Network (DQN) untuk melatih agen dalam environment CartPole-v1, dengan tujuan agar agen mampu menstabilkan posisi tiang pada kondisi tegak seimbang menggunakan aksi yang optimal. Dalam percobaan ini digunakan beberapa library, antara lain *gymnasium* untuk membangun environment DRL, *numpy* untuk melakukan operasi numerik, *random* untuk proses pemilihan acak,

serta *deque* untuk menyimpan pengalaman agen selama pelatihan. Model jaringan saraf dikembangkan menggunakan *tensorflow.keras*, sedangkan agen DQN diatur dengan beberapa parameter penting seperti *gamma* sebagai faktor diskon, *epsilon* untuk pengaturan tingkat eksplorasi, dan *learning rate* untuk proses optimasi.





Pada percobaan di environment CartPole-v1, agen diminta untuk menjaga tiang tetap tegak di atas gerobak. Lingkungan ini tergolong sederhana, sehingga agen cepat belajar. Setiap kali agen berhasil menyeimbangkan tiang, reward positif diberikan. Pelatihan pada CartPole relatif singkat dan agen dapat mencapai performa stabil dalam beberapa ratus episode karena kondisi lingkungan mudah diprediksi.



Pada Pendulum-v1, agen menghadapi tantangan yang berbeda namun tetap kompleks. Tugas utama agen adalah menjaga bandul agar tetap tegak di posisi seimbang, padahal secara alami bandul selalu berayun akibat gaya gravitasi. Tantangan muncul karena aksi yang dilakukan bersifat kontinu, sehingga agen harus belajar mengeluarkan gaya atau torsi dengan besar dan arah yang tepat untuk menahan atau mengayunkan bandul ke posisi ideal. Reward pada environment ini juga tidak mudah diperoleh karena kesalahan kecil dalam pengendalian dapat menyebabkan bandul kehilangan keseimbangan. Akibatnya, proses pembelajaran membutuhkan lebih banyak episode agar agen dapat menemukan strategi yang stabil, dan nilai reward sering berfluktuasi cukup besar sebelum akhirnya konvergen pada performa yang optimal.

Secara keseluruhan, eksperimen menunjukkan bahwa kompleksitas lingkungan sangat memengaruhi kecepatan belajar dan stabilitas agen, di mana lingkungan sederhana memungkinkan agen cepat mencapai tujuan, sedangkan lingkungan yang lebih menantang memerlukan strategi belajar yang lebih matang dan proses pelatihan yang lebih panjang.

6. Data dan Output Hasil Pengamatan

No.	Kondisi	Hasil Pengamatan	
		ChartPole-v1	Pendulum-v1
1.	Waktu Pelatihan	CartPole-v1 lebih cepat mencapai performa optimal dalam waktu	Pendulum-v1 membutuhkan waktu yang lebih lama agar

		yang relatif lebih singkat	hasil yang dihasilkan stabil
2.	Jumlah Episode Maksimum	CartPole-v1 dilatih hingga 1000-episode untuk mendapatkan hasil cukup baik 	Dengan jumlah episode yang sama tingkat kestabilan pendulum lebih baik 
3.	Kinerja Agen	Kinerja yang optimal dengan skor yang lebih tinggi.	Ketika sedang melakukan pekerjaan hasil yang stabil ketika mendekati 0
4.	Reward Awal	Reward awal masih bernilai rendah karena agen belum menjaga keseimbangan.	Reward awal masih bernilai rendah karena agen belum bagus.
5.	Hasil Test Episode	 Pengujian dilakukan dengan 25 episode dengan rata-rata <i>score</i> 499 menandakan mendekati nilai sempurna	 Pengujian dilakukan dengan 20 episode dengan <i>score</i> rata-rata lebih dari -200 menandakan sudah baik

6.	Grafik	 Grafik menunjukan pengujian selama 25 episode terjadi penurunan score pada episode 15 dengan score 320	 Grafik menunjukan selama 20 episode testing menghasilkan score range -325 sampai dengan mendekati 0 sebanyak 4 episode
----	--------	---	---

7. Kesimpulan

Berdasarkan percobaan yang telah dilakukan maka dapat diambil kesimpulan sebagai berikut:

1. Semakin banyak jumlah episode yang dilakukan pada saat proses *train* maka score yang dihasilkan saat pengujian akan bagus juga.
2. Algoritma DQN berhasil diterapkan untuk dua agen yang berbeda yaitu CartPole-v1 dan Pendulum-v1
3. Waktu pelatihan pada pendulum-v1 membutuhkan waktu yang lebih lama dibandingkan pada CartPole-v1 dengan jumlah episode yang sama yaitu 1000 episode
4. Dari grafik yang dihasilkan terlihat pada CartPole-v1 pada saat proses pelatihan terdapat penurunan nilai di sekitar 600 episode baru setelah itu stabil kembali, sedangkan pada pendulum-v1 mendapatkan nilai yang stabil sekitar 300 episode

8. Saran

Supaya agen DQN bisa bekerja lebih baik di lingkungan yang lebih sulit, kita bisa mencoba mengatur ulang beberapa parameter melalui berbagai percobaan. Misalnya, dengan menggunakan varian seperti *dueling DQN*, menambahkan *prioritized experience replay*, atau memperbanyak jumlah neuron dan lapisan pada jaringan saraf. Untuk kasus tertentu seperti *MountainCar*, metode lain seperti *actor-critic* atau *policy-based reinforcement learning* juga bisa dicoba agar proses belajar lebih cepat. Selain itu, memakai perangkat keras yang lebih kuat seperti GPU akan

membantu mempercepat proses pelatihan, terutama jika lingkungan atau model yang digunakan cukup kompleks.

9. Daftar Pustaka

- Brockman, G., Cheung, V., Pettersson, L., Schneider, J., Schulman, J., Tang, J., & Zaremba, W. (2016). *OpenAI Gym*. 1–4. <http://arxiv.org/abs/1606.01540>
- Mnih, V., Kavukcuoglu, K., Silver, D., Rusu, A. A., Veness, J., Bellemare, M. G., Graves, A., Riedmiller, M., Fidjeland, A. K., Ostrovski, G., Petersen, S., Beattie, C., Sadik, A., Antonoglou, I., King, H., Kumaran, D., Wierstra, D., Legg, S., & Hassabis, D. (2015). Human-level control through deep reinforcement learning. *Nature*, 518(7540), 529–533. <https://doi.org/10.1038/nature14236>